

<학술논문>

DOI <https://doi.org/10.3795/KSME-B.2020.44.4.237>ISSN 1226-4881(Print)
2288-5234(Online)일차원 합성곱 신경망을 이용한 치매 환자의 뇌파 분류[§]

심희동* · 정미리** · 이미현*** · 양석조*†

* 충남대학교 메카트로닉스공학과, ** 충남대학교 간호대학 근거기반간호지식교육센터,
*** 대전보건대학교 간호학과Classification of EEG for Dementia Patients
with One-Dimensional Convolution Neural Network

Hee-Dong Sim*, Mi-Ri Jeong**, Mi-Hyun Lee*** and Seok-Jo Yang*†

* Dept. of Mechatronics Engineering, Chungnam Nat'l Univ.,

** Research and Education Center for Evidence Based Nursing Knowledge, College of Nursing, Chungnam Nat'l Univ.,

*** College of Nursing, Daejeon Health Institute of Technology

(Received August 2, 2019 ; Revised January 10, 2020 ; Accepted January 16, 2020)

Key Words: Electroencephalography(뇌파), Dementia(치매), Convolution Neural Network(합성곱 신경망), Short-Time Fourier Transform(국소 푸리에 변환), Dementia Diagnosis(치매 진단)

초록: 대부분의 치매는 비가역적이기 때문에 조기 진단이 매우 중요하다. 하지만 현재 사용되고 있는 치매 진단 방법은 많은 한계점들을 가지고 있다. 이러한 문제를 해결하기 위해 치매와 정상인을 분류하기 위한 다양한 연구가 진행되어 왔다. 본 연구에서는 뇌파를 사용하여 정상인과 치매 환자를 분류하기 위해 신호 처리 방법과 일차원 합성곱 인공신경망 분류기를 제안한다. 치매 환자 13명과 정상인 115명의 뇌파 신호를 사용하였으며, 국소 푸리에 변환된 데이터셋으로 제안된 분류기의 성능을 교차 검증하였다. 제안된 인공신경망의 분류 성능은 두 개의 전극만으로 정확도 86.04%, 민감도 82.53%, 특이도 88.69%의 높은 성능을 나타내었다. 이를 통해 본 연구에서 제안된 일차원 합성곱 인공신경망 분류기와 신호 처리 방법이 정상인과 치매 환자의 뇌파를 높은 정확도로 분류할 수 있음을 확인하였다.

Abstract: Since most dementia cases are irreversible, early diagnosis is critical. However, dementia diagnosis methods have several limitations. In this regard, numerous studies have tried to classify dementia patients and healthy persons. In this study, we propose a 1-dimensional (1D) convolution neural network classifier and signal processing methods to distinguish between dementia patients and healthy persons through electroencephalography (EEG). We used EEG data from 13 dementia patients and 115 healthy people. In addition, a dataset transformed by the short-time Fourier transform was used to cross-validate the proposed artificial neural network classifier. The performance of the proposed classifier was 86.04 % accuracy, 82.53 % sensitivity, and 88.69 % specificity. This is a remarkable performance for only two electrodes. These results confirmed that EEG of healthy persons and dementia patients can be classified accurately with the 1D convolution neural network classifier and the signal processing methods proposed in this study.

1. 서 론

전세계적인 고령 인구 급증과 함께, 대표적인 노인성 질환 중 하나인 치매(dementia)에 의한 사

회적 비용이 빠르게 증가하고 있다.^(1~4) World Alzheimer Report 2018에 의하면, 현재 전세계적으로 치매로 인해 발생하는 사회적 비용이 약 1,000조에 달하고 있으며, 2030년에는 두 배로 증가할 것으로 예측되고 있다.⁽³⁾ 국내의 경우, 통계 자료에 의하면 2019년 65세 이상의 고령 인구는 전체 인구의 14.9%이며, 전국 치매 환자 수는 약 75만 명으로, 이는 전체 노인 인구의 10%에 달하는 수준이다.⁽⁵⁾ 또한 2030년까지 국내의 65세 이상 고

§ 이 논문은 대한기계학회 바이오공학부문 2019년 춘계학술대회(2019. 4. 24.-26., 해운대 한화리조트) 발표 논문임.

† Corresponding Author, sjyang@cnu.ac.kr

© 2020 The Korean Society of Mechanical Engineers

령 인구 비율이 전체 인구의 25%에 달할 것으로 예측되고 있어, 치매에 의해 발생될 사회적 비용은 더욱 커질 전망이다.^(4,6)

아직까지 대부분의 치매는 정확한 원인이 밝혀져 있지 않고, 비가역성(irreversibility)을 가지고 있어 완치하는 것이 불가능하다. 따라서 조기에 치매를 발견하고 적절한 관리를 통해 증상의 발현을 늦추는 것이 무엇보다도 중요하다.^(2,7-10) 현재 사용되고 있는 치매 진단 방법으로는 간이 정신 상태 검사(mini mental state examination), 컴퓨터 단층촬영(computed tomography), 자기 공명 영상(magnetic resonance imaging), 뇌혈류 부하 단층 영상 검사(single photon emission computed tomography), 뇌척수액 검사(cerebro-spinal fluid examination) 등의 방법이 있다. 하지만 이러한 방법들은 높은 비용이 요구되거나, 침습적(invasive) 방법에 의한 피검자의 고통을 동반하며, 하나의 확실한 검사가 없어서 여러 검사 결과를 종합적으로 사용하여야 하는 등의 여러 한계점들을 가지고 있다.^(9,10)

이러한 치매 진단 방법의 한계점 극복을 위해 뇌의 신경 활동을 직·간접적으로 나타내는 기능적 자기 공명 영상(fMRI: functional Magnetic Resonance Imaging), 뇌자도(magnetoencephalography), 뇌파(electroencephalography) 등을 이용한 다양한 연구들이 진행되어왔다.^(7,10-13) Peraza 등은 기능적 자기 공명 영상(fMRI)을 이용하여 루이소체 치매 환자의 증상 중 하나인 인지 기능의 요동 증상과 관련된 영역을 추적하였다.⁽¹¹⁾ Hornero 등은 알츠하이머 병(Alzheimer disease) 환자와 정상인의 뇌자도(MEG) 스펙트럼 분석을 통해 환자와 정상인을 분류하였다.⁽¹²⁾ Jang 등은 치매 환자와 정상인 뇌파의 정량적 주파수 분석법을 통해 두 그룹의 뇌파 간에 상이한 차이가 있음을 확인하였다.⁽¹³⁾

이 중 뇌파(EEG: Electroencephalography)는 뇌 신경 사이에 신호가 전달될 때 발생하는 전기의 흐름을 측정하는 방법으로, 두피에서 비침습적(non-invasive)으로 측정 가능하며, 연속적인 뇌 신경의 활동을 정량적이고 객관적으로 측정할 수 있는 방법이다.⁽¹³⁾ 또한 기능적 자기 공명 영상(fMRI), 기능적 근적외 분광법(fNIRS: functional Near-Infrared Spectroscopy) 등 대뇌 신경계를 구성하는 신경세포들의 혈류역학(hemodynamics)을 관찰하는 간접적 방법과는 다르게, 뇌파는 대뇌피질에서 발생하는 시냅스 후전위와 밀접한 연관을 가지고 있어 신경세포의 전기적 활동을 직접적으로 반영하고 있으며, 매우 뛰어난 시간 해상도

(temporal resolution)를 가지고 있다.^(14,15)

최근 치매 환자와 정상인의 뇌파 분류를 위해 높은 분류 성능을 가진 인공신경망을 활용한 연구가 활발히 진행되고 있다.⁽¹⁶⁻¹⁸⁾ Metin 등은 MLP(Multi-Layered Perceptron) network를 통해 조울증 환자와 전두측두엽 치매 환자의 뇌파를 87%의 높은 정확도로 분류하였으며,⁽¹⁶⁾ Durongbhan 등은 KNN(K-Nearest Neighbor) 알고리즘을 이용하여 알츠하이머병 환자와 정상인의 뇌파를 매우 높은 정확도로 분류하였다.⁽¹⁷⁾ Ieracitano 등은 알츠하이머병 환자와 MCI(Mild Cognitive Impairment) 환자, 그리고 정상인의 뇌파의 파워 스펙트럼 밀도(power spectral density)와 CNN (Convolution Neural Network)을 이용하여 80% 이상의 정확도로 분류하였다.⁽¹⁸⁾

본 연구에서는 정상인과 치매 환자의 뇌파 분류를 위한 국소 푸리에 변환을 이용한 신호 처리와 일차원 합성곱 인공신경망 분류기를 제안한다. 치매 환자 13명의 뇌파와 정상인 115명의 전전두엽 위치에 해당하는 2채널(Fp1, Fp2)의 뇌파 신호를 측정하였으며, 노이즈 제거를 위한 전처리 및 푸리에 변환(Fourier transform)의 상대적 크기를 이용하여 델타(δ) 영역을 제거한 국소 푸리에 변환(short-time Fourier transform)을 수행하여 시간-주파수 영역으로 데이터를 변환하였다. 변환된 데이터를 이용해 일차원 합성곱 신경망(1-dimensional convolution neural network) 모델을 이용하여 지도 학습 및 분류 성능을 평가하였다.

2. 연구 내용 및 방법

2.1 뇌파 데이터 측정 및 신호 처리

본 연구에서는 PhysioNet의 BCI2000 데이터셋 중 REO(Resting, Eyes Open) 상태에서 각 61초 동안 측정된 109명의 정상인(control) 뇌파 데이터와 추가로 측정된 여섯 명의 정상인 REO 상태 뇌파를 전체 정상인 데이터로 활용하였다.^(19,20) 치매 환자(dementia)의 경우, 특별히 치매 종류를 구분하지 않고 총 13명의 치매 환자의 REO 상태 뇌파를 오전/오후 총 2회씩 나누어 측정하였다.

2.1.1 뇌파 데이터 측정


뇌파 측정 시 전극의 위치는 국제 10-10 전극배치법(international 10-10 electrode positioning system)의 전극 중 모발이 없어 측정이 간편하고, 인지 제어(cognitive control)와 밀접히 관련된 전전두엽(prefrontal cortex)의 위치에 해당하는 Fp1과 Fp2 전

Table 1 Information of dementia subjects

Subject	Sex	Diseases	GDS*
01	Male	AD*	4
02	Male	Parkinson/AD*	5
03	Male	Epilepsy/AD*	5
04	Female	VaD [△]	6
05	Female	VaD [△]	6
06	Female	AD*	6
07	Female	AD*	6
08	Female	AD*	6
09	Male	AD*	5
10	Male	AD*	5
11	Female	AD*	6
12	Female	AD*	5
13	Female	AD*	5

*AD : Alzheimer's disease; [△]VaD : Vascular dementia;

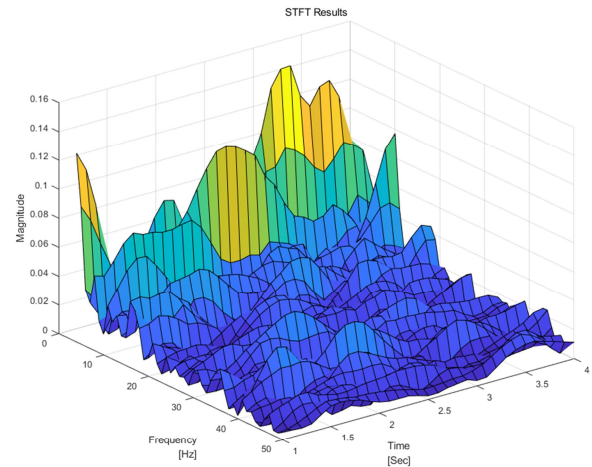
※GDS: Global deterioration scale


Fig. 1 EEG acquired electrode position in International 10-10 Electrode Positioning System

극을 사용하였다.^(21,22) GND 전극은 A1 위치를, Ref는 A2 위치를 사용하였다. BCI2000 데이터셋을 제외한 뇌파 데이터는 PolyG-I(Laxtha, Inc., Korea)를 이용하여 측정되었으며, 샘플링 주파수는 256Hz로 측정하였다.

2.1.2 전처리(preprocessing)

뇌파 신호에는 일반적으로 안구의 움직임 등에 의해 발생하는 EOG(Electrooculography), 근육의 움직임 등에 의해 발생하는 EMG(Electromyography), 심장 박동에 의해 발생하는 ECG(Electrocardiogram), 그리고 측정 환경 주변의 전력선에 의해 발생하는 60Hz 등 많은 노이즈가 포함되어


Fig. 2 STFT processed EEG sample in time-frequency representation

있다. 이를 제거하기 위해 저역 통과 및 대역 저지의 버터워스(butterworth) 필터를 적용하였다. 저역 통과 필터의 차단 주파수는 50Hz, 대역 저지 필터는 55Hz, 65Hz로 설정하였다. 중증 치매 환자의 경우 측정 시 검사자의 지시를 잘 따르지 않고 움직이려고 하는 경우가 있었다. 움직임에 의해 발생한 노이즈가 매우 심각한 경우 해당 영역은 데이터에서 제거하였다.

2.1.3 국소 푸리에 변환

국소 푸리에 변환(STFT: Short-Time Fourier Transform)은 신호의 전체 주기에서 일정한 창 함수(window function)를 시간 축에 따라 이동시키면서 원 신호와의 곱 연산(subsampling)된 결과에 푸리에 변환을 적용한다. 국소 푸리에 변환은 일반적으로 다음 식 (1)과 같이 정의된다.

$$X(\tau, \omega) = \int_{-\infty}^{\infty} x(t)w(t - \tau)e^{-j\omega t} dt \quad \dots \quad (1)$$

일정한 주파수로 샘플링된 데이터의 국소 푸리에 변환은 다음 식 (2)와 같이 정의된다.

$$X(\tau, \omega) = \sum_{n=-\infty}^{\infty} x[n]w[n - \tau]e^{-j\omega t} \quad \dots \quad (2)$$

국소 푸리에 변환은 창 함수의 길이가 길수록 주파수 해상도가 증가하고 시간 해상도가 감소하는 trade-off 관계가 있기 때문에 창 함수를 시간 축에 따라 이동시킬 때 일정한 overlap 비율을 설정하여 변환을 수행하였다. 데이터 샘플링은 4초 동안의 길이만큼 샘플링하고 1초 길이의 해밍 창(hamming window)을 사용하여 서브샘플링을 수행하였다. 이때 움직임 등에 의한 노이즈 성분이 많

은 델타(δ) 영역(0.5~4Hz)을 제거한 세타, 알파, 베타, 감마($\theta, \alpha, \beta, \gamma$) 영역에 해당하는 4Hz~50Hz 영역의 전체 크기 합에 대한 상대적 크기(relative magnitude)를 사용하여 각 샘플 데이터가 정규화(normalize)되도록 하였다. 이렇게 국소 푸리에 변환을 통해 시간-주파수의 2D 데이터로 표현된 뇌파 데이터를 본 연구에서 제안하는 인공신경망으로 분류하였다.

2.2 인공신경망 분류기

본 연구에서 뇌파 데이터 분류를 위해 제안하는 인공신경망 모델은 한 개의 layer로 구성된 일차원 합성곱 신경망과 max pooling layer, 그리고 두 개의 fully connected network로 구성된 신경망이다. 입력된 데이터의 클래스 예측은 마지막 출력 layer에서 각 클래스에 속할 확률 값이 계산(softmax)되고, 이 중 더 큰 값을 가진 클래스(argmax)를 입력된 데이터의 클래스로 결정한다.

제안된 인공신경망 모델의 성능을 5-fold 교차 검증하여 결과를 확인하고 모델의 분류 성능을 검증하였다.

2.2.1 일차원 합성곱 신경망

첫 번째 layer인 일차원 합성곱 layer에서는 입력된 2차원 데이터로부터 각 주파수 축과 동일한 길이를 가진 여러 개의 필터를 time 축을 따라 이동하며 일차원 합성곱 연산을 수행하여 각각의 필터에 의해 계산된 특성(feature) 활성도를 구한다. 각 feature 값은 max pooling layer에서 최대 활성 값이 Sigmoid 활성화 함수를 거쳐 다음 layer로 전달된다. 일반적인 CNN(Convolution Neural Network)에서는 ReLU(Rectified Linear Unit) 함수를 활성화 함수로 사용하지만, 본 연구에서 제안하는 모델은 신경망의 깊이가 vanishing gradient 등의 문제가 발생

할 만큼 깊지 않으므로 시그모이드 함수(Sigmoid)를 사용하였다. 다음으로 세 개의 layer로 구성된 fully connected layer에서 max pooling layer로부터 전달받은 각 합성곱 필터의 활성도 값을 이용하여 정상인(control), 치매 환자(dementia) 각각의 클래스에 속할 확률을 구한다. 최종 layer에서 계산된 확률값들은 다시 출력 layer의 모든 활성도 값을 0~1 사이의 상대적인 확률값으로 변환하는 소프트맥스(softmax) 함수를 적용하였다. 소프트맥스 함수는 식 (3)과 같이 표현된다.

$$\text{Softmax}(x_i) = \frac{\exp(x_i)}{\sum_j \exp(x_j)} \quad \dots \quad (3)$$

인공신경망 모델 구현은 Google사의 Tensorflow를 사용하여 구현되었으며, 모든 가중치와 바이어스의 초기값은 평균 0, 표준 편차 1을 가지는 truncated normal distribution으로 무작위 초기화를 진행하였으며, 학습 과정에는 mini-batch와 adam optimizer를 적용하여 가중치와 바이어스 값의 업데이트 시 error 및 momentum을 함께 사용하여 학습하였다.

비용 함수(cost function)는 softmax 함수로부터 출력된 각 클래스에 해당할 확률 값과 입력 데이터의 원래 클래스 값의 cross entropy로 정의되었다(식 (4)). 여기서 p와 q는 각각 실제 클래스 값과 인공신경망 모델에 의해 계산된 각 클래스에 해당할 확률 값이다.

$$\text{Cost}(p, q) = -\sum_x p(x) \log q(x) \quad \dots \quad (4)$$




Fig. 3 Proposed 1-D convolution neural network model structure




Fig. 4 How 1-dimensional convolution filter works

Table 2 Confusion matrix

		Model predicted		
		Dementia	Control	
Real	Dementia	TP	FN	P
	Control	FP	TN	N

또한 훈련 과정에서 발생할 수 있는 과적합을 방지하기 위해 훈련 과정에서는 fully connected layer에 drop out을 적용하였다.

2.2.2 모델 성능 검증

인공신경망 모델을 학습시킬 데이터가 적은 경우, 일반적인 방식인 훈련용, 평가용, 검증용으로 데이터셋을 나누는 것은 검증 성능의 신뢰도를 감소시킬 수 있다. 따라서 이러한 문제점을 피하기 위해, 본 연구에서는 전체 데이터셋을 K개의 부분 집합으로 나누고, 하나의 부분 집합을 검증 데이터로, 나머지 데이터를 훈련 데이터로 사용한 뒤 이를 각각의 부분 데이터셋의 개수인 K번만큼 반복하면서, 평균 검증 성능을 사용하는 K-fold 교차 검증(K-fold cross validation) 방식을 사용하였다. 교차 검증을 위해 각 데이터셋을 나눌 때에는 각각의 측정 대상별로 데이터를 나누어 특정 인원의 데이터가 모두 제외되지 않도록 하였고, 각각 일부는 검증 데이터, 일부는 학습 데이터로 사용되도록 분할하였다.

제안된 분류 모델의 성능 검증을 위해 다음과 같이 검증 파라미터를 정의하였다.

(a) 혼동 행렬(confusion matrix)

혼동 행렬(confusion matrix)은 분류기(classifier)의 성능을 평가하는데 자주 사용되는데, 각각의 항목들은 TP (True Positive), FN(False Negative), FP(False Positive), 그리고 TN(True Negative)이며 다른 평가 파라미터들을 구하기 위해 사용된다.

(b) 정확도(accuracy)

$$\text{Accuracy} = \frac{TP + TN}{P + N}$$

정확도는 전체 데이터에 대한 분류 정확도를 나타낸다.

(c) 민감도(sensitivity, recall)

$$\text{Sensitivity} = \frac{TP}{P}$$

민감도(sensitivity, recall)는 치매 환자의 뇌파 데

이터 중에서 분류기 모델이 치매로 분류한 비율을 나타낸다.

(d) 특이도(specificity)

$$\text{Specificity} = \frac{TN}{N}$$

특이도(specificity)는 분류기 모델이 정상인 데이터 중에서 정상인으로 분류한 비율을 나타낸다.

(e) 정밀도(precision)

$$\text{Precision} = \frac{TP}{TP + FP}$$

정밀도(precision)는 분류기 모델이 치매로 분류한 뇌파 데이터 중에서 실제 치매 환자의 데이터 비율이다.

(f) F1 점수(F1 score)

$$\text{F1 score} = 2 \cdot \frac{\text{Precision} \cdot \text{Sensitivity}}{\text{Precision} + \text{Sensitivity}}$$

F1 점수(F1 score)는 정밀도와 민감도의 조화 평균값이다. 일반적으로 분류기 성능을 하나의 숫자로 나타내고자 할 때 주로 사용되는 파라미터이다. 0과 1 사이의 값을 가지며, 1에 가까울수록 높은 성능임을 나타낸다.

(g) 수신자 조작 특성 곡선(ROC curve: Receiver operating characteristic curve)

수신자 조작 특성 곡선(ROC curve)은 입력된 데이터가 각각의 클래스에 해당할 확률이 0~1 사이의 기준(threshold)에 따라 얼마나 명확하게 분류하는가를 나타낸다. 가로축은 1-특이도(false positive rate), 세로축은 민감도이며, 기준이 이동됨에 따라서 다르게 분류된 결과를 나타낸다. ROC curve는 그래프이므로 면적에 해당하는 AUC(Area Under Curve)를 사용하여 모델의 성능을 평가하며, AUC가 1에 가까울수록 각 그룹 간의 분류가 명확하게 분류됨을 나타낸다. 또한 ROC curve가 y=x의 꼴로 나타나는 경우에는 모든 예측이 모두 무작위로 선택하는 확률과 같다는 의미이다.

3. 결과 및 고찰

본 연구에서 제안된 뇌파 신호 처리 및 인공신경망 모델을 통해 치매 환자와 정상인의 뇌파를 분류하고 모델의 성능을 5-fold 교차 검증을 통해 확인하였다. 데이터 변환 및 인공신경망 모델의

Table 3 Parameter settings of proposed model

Dataset processing parameters		
Parameter	Value	Unit
Sample time	4	Second
Sample overlap	25	%
Subsample time	1	Second
Subsample overlap	90	%
Subsample frequency range	4~50	Hz
Neural network parameters		
Parameter	Value	
K-fold	5-fold cross validation	
Mini-batch size	30% of train data	
Adam optimizer: β_1, β_2	0.9, 0.999	
Drop out probability	50%	
Train iteration	5,000	
CNN: Filter number	60	
CNN: Filter thickness*	20	
FC layer: Neurons	40	

*Filter thickness: Filter length along the time axis

Table 4 STFT processed EEG dataset statistics

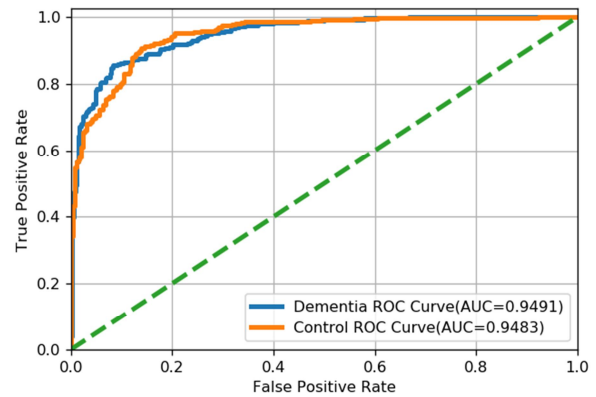
	Number of data	Data ratio
Dementia	1,470	42.07%
Control	2,024	57.93%
Total	3,494	100%

Table 5 Proposed classifier model performance (average)

Accuracy	86.04%
Sensitivity	82.53%
Specificity	88.69%
Precision	84.19%
F1 score	0.8332
AUC of ROC (dementia)	0.9399
AUC of ROC (control)	0.9395

파라미터 설정은 Table 3과 같다. 이와 같은 설정을 통하여 제안하는 인공신경망 모델을 훈련시키고 성능을 검증하였다. Table 5와 Fig. 5는 제안된 일차원 합성곱 신경망의 분류 성능이다. 제안된 모델의 분류 성능은 정확도가 86.04%, 민감도 88.69%, 특이도 82.53%, 그리고 0.8332의 F1 score로 정상인과 치매 환자의 분류 성능이 높은 것을 확인할 수 있다.

본 연구에서 데이터 처리는 두 개의 전전두엽 위치 전극의 뇌파 신호로부터 델타파를 제거하여

**Fig. 5** ROC curve of one of folded-model performance

푸리에 변환의 상대적인 크기를 이용한 STFT 변환을 사용하였고, 이를 CNN 분류기로 학습 및 분류하였다. 이를 통해 훨씬 적은 수의 전극과 단순한 분류 네트워크로도 좋은 성능을 나타낸 타 연구 결과와 비슷한 수준의 분류 성능을 보이는 것을 확인하였다.

Fig. 5는 5-fold로 교차 검증된 분류 성능 중 하나의 fold에서의 ROC curve이며, 모든 fold된 데이터셋에서 거의 유사한 수준의 ROC curve가 나타났다. ROC curve가 치매 환자와 정상인에 대하여 각각 그려진 이유는 제안된 모델의 최종 클래스 판정 방식이 각각의 클래스에 속할 확률 중 더 큰 확률을 선택하는 방식이기 때문이다. 정상인과 치매 환자의 ROC curve의 AUC가 각각 0.9399, 0.9395로 높아 치매와 정상인 두 클래스의 뇌파 데이터를 잘 분류하고 있으며, 추후 다양한 치매의 원인 등을 분류할 수 있는 다중 클래스 분류기 모델의 기반이 될 수 있을 것으로 기대된다.

본 연구에서 사용된 뇌파 데이터의 경우 출처가 서로 다른 데이터가 섞여 있어 경계하여야 할 필요가 있다. 특히 BCI2000 데이터셋의 경우 치매 환자와 서로 다른 샘플링 주파수를 가지고 있으므로 이를 보완하기 위해 치매 환자와 동일한 장비로 측정된 정상인 여섯 명의 뇌파 데이터를 추가로 사용하여 분류하였으며, 각 데이터를 정량적 주파수 분석 및 상대적 크기를 통한 정량화를 사용하였다. 치매 환자와 같은 환경에서 측정된 정상인 여섯 명의 결과가 BCI2000 데이터셋의 정상인 결과가 거의 유사하였기 때문에 특별한 문제는 확인되지 않았다.

이러한 결과들을 통해, 모발이 없어 측정이 간편하고, 전전두엽 기능을 나타내는 Fp1과 Fp2, 두 개의 채널의 뇌파 신호와 본 연구에서 제안된 인공신경망 모델 및 신호 처리 방법을 통해 높은

정확도로 치매 환자와 정상인 간의 분류가 가능함을 확인하였다. 향후 본 연구에서 제안된 방법을 통해 매우 쉽고 간편하면서도 높은 정확도를 가진 치매 진단 도구의 개발로 이어질 수 있을 것으로 기대한다. 아울러 최근 많은 연구가 진행되고 있는 BCI(Brain Computer Interface)와 같은 분야에서도 인간의 정신 기능을 측정 및 정량화하고 이를 분석하기 위한 방법으로써 제시될 수 있을 것이다.

4. 결 론

본 연구에서는 두 개 채널의 뇌파를 이용하여 치매 환자와 정상인의 뇌파를 분류하기 위한 신호 처리 방법과 일차원 합성곱 인공신경망 분류기를 제안하였다. 본 연구에서 제안하는 모델은 치매 환자 13명과 정상인 115명의 REO 상태의 뇌파 데이터에 상대적 크기를 사용한 국소 푸리에 변환을 적용한 뒤 일차원 합성곱 신경망을 통해 분류하였다. 분류기 모델의 성능 검증은 5-fold 교차 검증을 사용하였으며, 평균 86.04%의 정확도(accuracy), 민감도(sensitivity) 82.53%, 특이도(specificity) 88.69%, 그리고 0.8332의 F1 score로 높은 분류 성능을 가지고 있었고, AUC(Area Under Curve)는 평균 0.93 이상의 높은 분류 성능을 나타내었다. 본 연구에서 제안하는 신호 처리 방법과 일차원 합성곱 신경망 분류기를 통해 정상인과 치매 환자의 뇌파를 높은 성능으로 분류할 수 있음을 확인하였으며, 추후 대량의 뇌파 데이터와 함께 다양한 치매 원인의 분류, 치매 정도의 분류 등의 연구가 후속될 수 있을 것으로 기대된다.

후 기

이 연구는 2015년도 정부(교육부)의 재원으로 한국연구재단의 지원을 받아 수행된 기초연구사업임(No. 2015R1D1A3A01020469).

참고문헌 (References)

- (1) Livingston, G., Sommerlad, A., Orgeta, V., Costafreda, S. G., Huntley, J., Ames, D., Ballard, C., Banerjee, S., Burns, A., Cohen-Mansfield, J., Cooper, C., Fox, N., Gitlin, L. N., Howard, R., Kales, H. C., Larson, E. B., Ritchie, K., Rockwood, K., Sampson, E. L., Samus, Q., Schneider, L. S., Selbæk, G., Teri, L. and Mukadam, N., 2017, "Dementia Prevention, Intervention, and Care," *The Lancet Commissions*, Vol. 390, No. 10113, pp. 2673~2734.
- (2) Jeong, J. H., 2019, "Effect of Aerobic Exercise Program Participation on the Dementia-related Factor and Cognitive Function in Elderly Women with Dementia," *Journal of the Korea Convergence Society*, Vol. 10, No. 6, pp. 227~234.
- (3) Patterson, C., 2018, "World Alzheimer Report 2018: The State of the Art of Dementia Research: New Frontiers," *Alzheimer's Disease International (ADI)*, London, England, pp. 6~7.
- (4) Cho, H. S. and Cho, Y. H., 2019, *National Institute of Dementia Annual Report 2018*, National Institute of Dementia, Seoul, Korea, pp. 3~7.
- (5) Statistics Korea, 2017, *Population Projections for Korea*, Korean Statistical Information Service, Statistics Korea, Seoul.
- (6) Lee, J. B., Kang, H. W., Kim, J. U., Kim, G. H. and Kim, N. K., 2019, "A Study on Medical Expenses of Modern and Korean Medicine for Dementia Patients Under National Health Care," *Journal of Oriental Neuropsychiatry*, Vol. 30, No. 1, pp. 31~38.
- (7) Lee, J. E., Park, J. H. and You, S. J., 2017, "Combining Single-channel EEG Measurement and Verbal Fluency Test - A Groundwork for Ambulatory Diagnosis of Dementia," *14th International Conference on Ubiquitous Robots and Ambient Intelligence*, pp. 408~412.
- (8) Anuradha, G., Jamal, N. and Rafiammal, S., 2017, "Detection of Dementia in EEG Signal using Dominant Frequency Analysis," *IEEE International Conference on Power, Control, Signals and Instrumentation Engineering*, pp. 710~714.
- (9) Jang, S. H., Lee, Y. S., Lee, B. R., Kim, E., Choi, N. H., Park, B. H. and Lee, T. J., 2018, "Cost-Effectiveness of Diagnostic Technologies for Dementia: A Systematic Review of Economic Evaluation," *The Korean Journal of Health Economics and Policy*, Vol. 24, No. 1, pp. 36~65.
- (10) Pu, J., Wang, J., Zheng, Y. B., Ye, H., Shen, W. W., Li, Y. X. and Zha, H. Y., 2017, "Boosting Alzheimer Diagnosis Accuracy with the Help of Incomplete Privilege Information," *International Conference on Bioinformatics and Biomedicine*, pp. 595~599.
- (11) Peraza, L. R., Kaiser, M., Firbank, M., Graziadio, S., Bonanni, L., Onofrj, M., Colloby, S. J., Blamire, A., O'Brien, J. and Taylor, J.-P., 2014, "fMRI Resting State Networks and their Association with Cognitive Fluctuations in Dementia with Lewy Bodies," *NeuroImage: Clinical*, Vol. 4, pp. 558~565.
- (12) Hornero, R., Escudero, J., Fernández, A., Poza, J. and Gómez, C., 2008, "Spectral and Nonlinear

- Analyses of MEG Background Activity in Patients with Alzheimer's Disease," *IEEE Transactions on Biomedical Engineering*, Vol. 55, No. 6, pp. 1658~1665.
- (13) Jang, Y. S., Park, K. C. and Han, D. W., 2014, "Comparison of EEG Characteristics between Dementia Patient and Normal Person Using Frequency Analysis Method," *Journal of Korea Institute of Electronic Communication Science*, Vol. 9, No. 5, pp. 595~600.
- (14) Wang, C., Xu, J., Zhao, S. and Lou, W., 2019, "Identification of Early Vascular Dementia Patients with EEG Signal," *IEEE Access*, Vol. 7, pp. 68618~68627.
- (15) Burle, B., Spieser, L., Roger, C., Casini, L., Hasbroucq, T. and Vidal, F., 2015, "Spatial and Temporal Resolutions of EEG: Is It Really Black and White? A Scalp Current Density View," *International Journal of Psychophysiology*, Vol. 97, No. 3, pp. 210~220.
- (16) Metin, S. Z., Erguzel, T. T., Ertan, G., Salcini, C., Kocarslan, B., Cebi, M., Metin, B., Tanridag, O. and Tarhan, N., 2017, "The Use of Quantitative EEG for Differentiating Frontotemporal Dementia from Late-Onset Bipolar Disorder," *Clinical EEG and Neuroscience*, Vol. 49, No. 3, pp. 171~167.
- (17) Durongbhan, P., Zhao, Y., Chen, L., Zis, P., De Marco, M., Unwin, Z. C., Venneri, A., He, X., Li, S., Zhao, Y., Blackburn, D. J. and Sarrigiannis, P. G., 2019, "A Dementia Classification Framework Using Frequency and Time-Frequency Features Based on EEG Signals," *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, Vol. 27, No. 5, pp. 826~835.
- (18) Ieracitano, C., Mammone, N., Bramanti, A., Hussain, A. and Morabito, F. C., 2019, "A Convolutional Neural Network Approach for Classification of Dementia Stages Based on 2D-Spectral Representation of EEG Recordings," *Neurocomputing*, Vol. 323, No. 5, pp. 96~107.
- (19) Goldberger, A. L., Amaral, L. A. N., Glass, L., Hausdorff, J. M., Ivanov, P. Ch., Mark, R. G., Mietus, J. E., Moody, G. B., Peng, C.-K. and Stanley, H. E., 2000, "PhysioBank, PhysioToolkit, and PhysioNet: Components of a New Research Resource for Complex Physiologic Signals," *Circulation*, Vol. 101, No. 23, pp. e215~e220.
- (20) Schalk, G., McFarland, D. J., Hinterberger, T., Birbaumer, N. and Wolpaw, J. R., 2004, "BCI2000: A General-Purpose Brain-Computer Interface (BCI) System," *IEEE Transactions on Biomedical Engineering*, Vol. 51, No. 6, pp. 1034~1043.
- (21) Rouault, M. and Koechlin, E., 2018, "Prefrontal Function and Cognitive Control: From Action to Language," *Current Opinion in Behavioral Sciences*, Vol. 21, pp. 106~111.
- (22) Choi, J. M., Ku, B. C., You, Y. G., Jo, M. O., Kwon, M. J., Choi, Y. Y., Jung, S. G., Ryu, S. Y., Park, E. J., Go, H. Y., Kim, G. H., Cha, W. S. and Kim, J. W., 2019, "Resting-State Prefrontal EEG Biomarkers in Correlation with MMSE Scores in Elderly Individuals," *Scientific Report*, Vol. 9, No. 1, p. 10468.